RAPPORT DE PROJET

Semestre 8 — Data Science & Machine Learning

Détection de la Fraude Interne en Entreprise

Approche par Machine Learning & Triangle de Cressey

École	ENCG
Filière	Management & Data Science
Semestre	S8 — 2024/2025
Matière	Apprentissage Automatique
Date	Mars 2025
NOM ET APOGÉE	RIAD DOUAA 22006170 RHAOUTA SALMA 23009580

Table des matières

Table des matières 2
1. Introduction & Problématique 3
1.1 Cadre théorique : le Triangle de Cressey 3
2. Données & Méthodologie 4
2.1 Description du jeu de données 4
2.2 Variables explicatives 4
2.3 Pipeline méthodologique 4
3. Analyse Exploratoire (EDA) 5
3.1 Distribution de la variable cible 5
3.2 Taux de fraude par département 5
3.3 Score de Risque — Triangle de Cressey 6
3.4 Distribution des variables par statut de fraude 7
3.5 Matrice de corrélation 8
3.6 Impact déterminant de l'accès privilégié 9
3.7 Pression Financière vs Score de Risque 10
4. Modélisation Machine Learning 12
4.1 Algorithmes testés 12
4.2 Paramètres d'entraînement 12
5. Résultats & Comparaison des Modèles 13
5.1 Métriques de performance 13
5.2 Matrices de confusion 13
5.3 Courbes ROC 14
5.4 Importance des variables 15
5.5 Distribution des probabilités de fraude 17
5.6 Radar des performances 17
6. Modèle Recommandé : Régression Logistique 19
7. Recommandations Opérationnelles 20
7.1 Plan de déploiement du modèle 20
8. Conclusion 21
8.1 Limites & Perspectives 21

1. Introduction & Problématique

La fraude interne représente l'une des principales menaces pour l'intégrité organisationnelle des entreprises. Selon les études internationales, elle est responsable de pertes annuelles considérables et provient souvent d'employés en situation de vulnérabilité personnelle ou disposant d'accès privilégiés aux systèmes d'information.

Ce projet s'inscrit dans une démarche de prévention proactive : plutôt que d'attendre la détection post-facto, nous proposons un système de scoring prédictif basé sur les données comportementales et professionnelles des employés.

Problématique : Comment identifier, parmi 1 000 employés, les profils présentant un risque élevé de fraude interne en combinant un score théorique (Triangle de Cressey) et des algorithmes de Machine Learning supervisé ?

1.1 Cadre théorique : le Triangle de Cressey

Le Triangle de Cressey (1953) postule que la fraude survient lorsque trois conditions sont réunies simultanément :

- Pression financière : difficultés économiques personnelles poussant l'individu à agir
- Opportunité : accès aux ressources sensibles et faiblesse des contrôles internes
- Rationalisation : justification morale de l'acte frauduleux (insatisfaction, sentiment d'injustice)

Ce cadre théorique constitue le fondement de la construction du score de risque composite utilisé dans notre analyse.

2. Données & Méthodologie

2.1 Description du jeu de données

Caractéristique	Valeur
Nombre d'observations	1 000 employés
Variable cible	Fraude_Interne (0 = non, 1 = oui)
Taux de fraude global	**5 % — 50 cas détectés**
Déséquilibre des classes	950 non-fraudeurs / 50 fraudeurs (ratio 19:1)
Découpage entraînement/test	80 % / 20 %

2.2 Variables explicatives

Variable	Type	Description
Score_Pression_Financiere	Numérique 1–10	Pression financière personnelle estimée (Triangle de Cressey — Pression)
Satisfaction_Travail	Numérique 1–10	Indice de satisfaction au travail (Triangle de Cressey — Rationalisation)
Heures_Supp_Mois	Numérique	Nombre d'heures supplémentaires effectuées par mois
Conges_Non_Pris	Numérique	Jours de congés non consommés (signal comportemental)
Anciennete_Annees	Numérique	Ancienneté dans l'entreprise en années
Acces_Privilegie	Binaire 0/1	Accès aux systèmes d'information sensibles (Triangle de Cressey — Opportunité)
Departement	Catégorielle	RH, Ventes, Finance, Achats, Logistique, IT
Score_Risque	Numérique	Score composite calculé à partir du Triangle de Cressey

2.3 Pipeline méthodologique

Le projet suit une pipeline structurée en cinq étapes :

- Collecte & préparation des données (nettoyage, encodage des variables catégorielles)
- Analyse Exploratoire (EDA) : distributions, corrélations, analyse par segments
- Feature Engineering : construction du Score_Risque basé sur le Triangle de Cressey
- Modélisation : entraînement et validation de 4 algorithmes de classification
- Évaluation comparative & recommandations opérationnelles

3. Analyse Exploratoire (EDA)

3.1 Distribution de la variable cible

Le jeu de données présente un fort déséquilibre de classes, caractéristique habituelle des problèmes de détection de fraude :

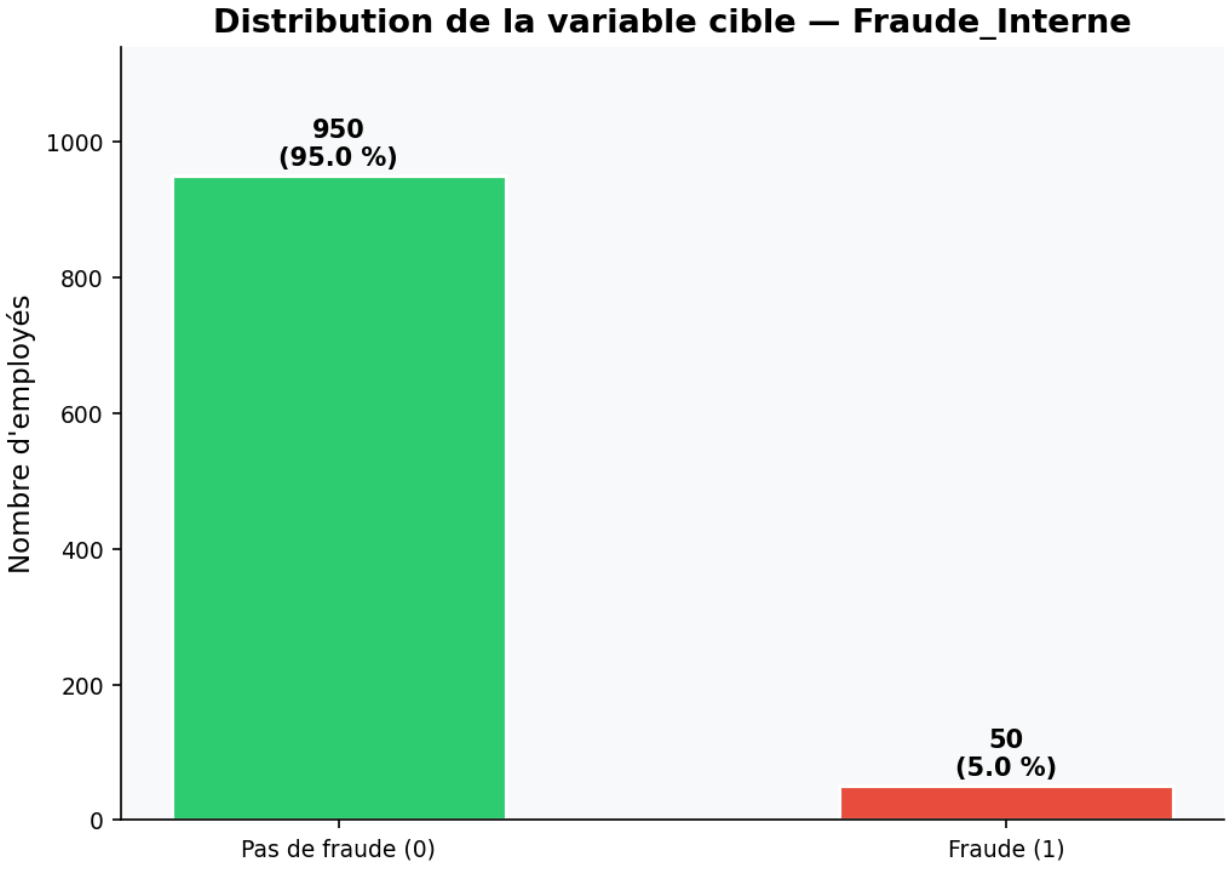

Figure 1 : Distribution de la variable cible — 950 non-fraudeurs (95 %) vs 50 fraudeurs (5 %)

⚠ **Point d'attention :** Ce déséquilibre (ratio 19:1) impose l'utilisation du paramètre class_weight='balanced' et l'interprétation prioritaire du Recall et du ROC-AUC plutôt que de l'Accuracy.

3.2 Taux de fraude par département

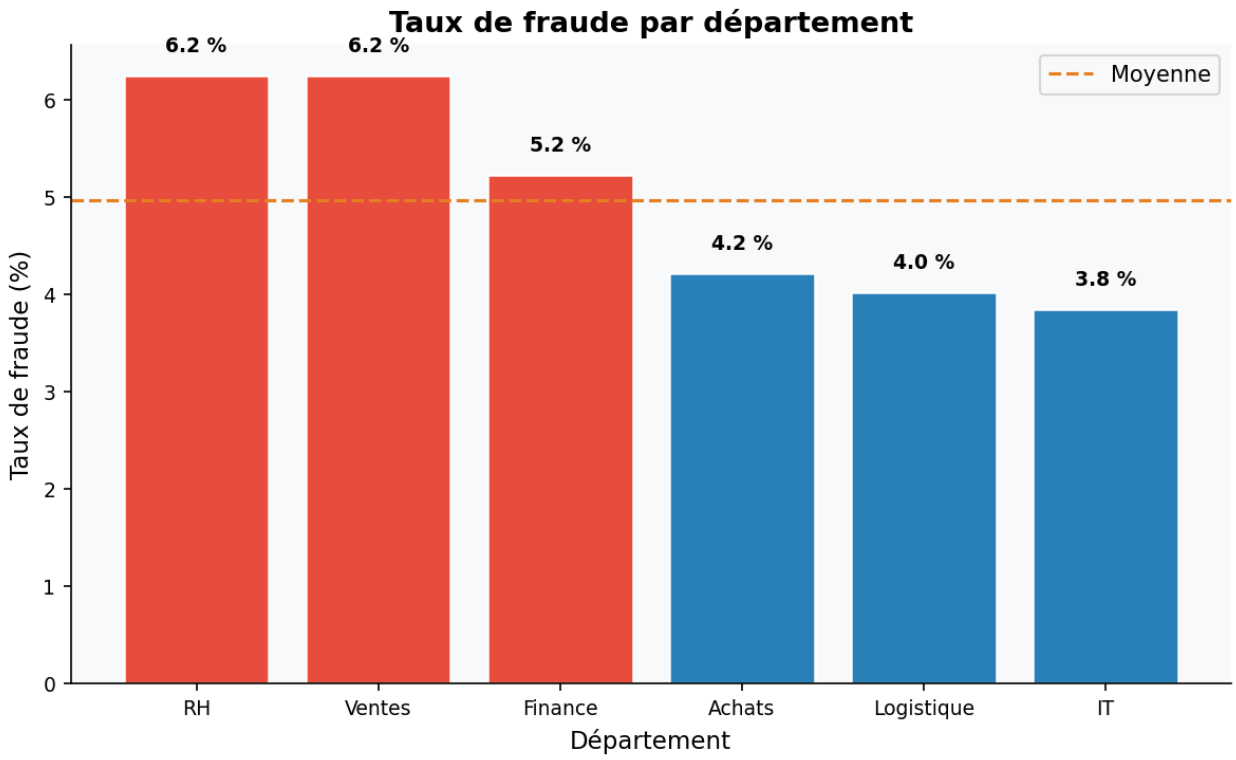

Figure 2 : Taux de fraude par département avec ligne de référence à la moyenne (5 %)

Département	Taux de fraude	Statut
RH	**6,2 %**	Au-dessus de la moyenne
Ventes	**6,2 %**	Au-dessus de la moyenne
Finance	**5,2 %**	Au-dessus de la moyenne
Achats	**4,2 %**	En dessous de la moyenne
Logistique	**4,0 %**	En dessous de la moyenne
IT	**3,8 %**	En dessous de la moyenne

3.3 Score de Risque — Triangle de Cressey

Le score de risque composite est construit comme une combinaison pondérée des trois dimensions du Triangle de Cressey. La distribution confirme la forte valeur discriminante de ce score :

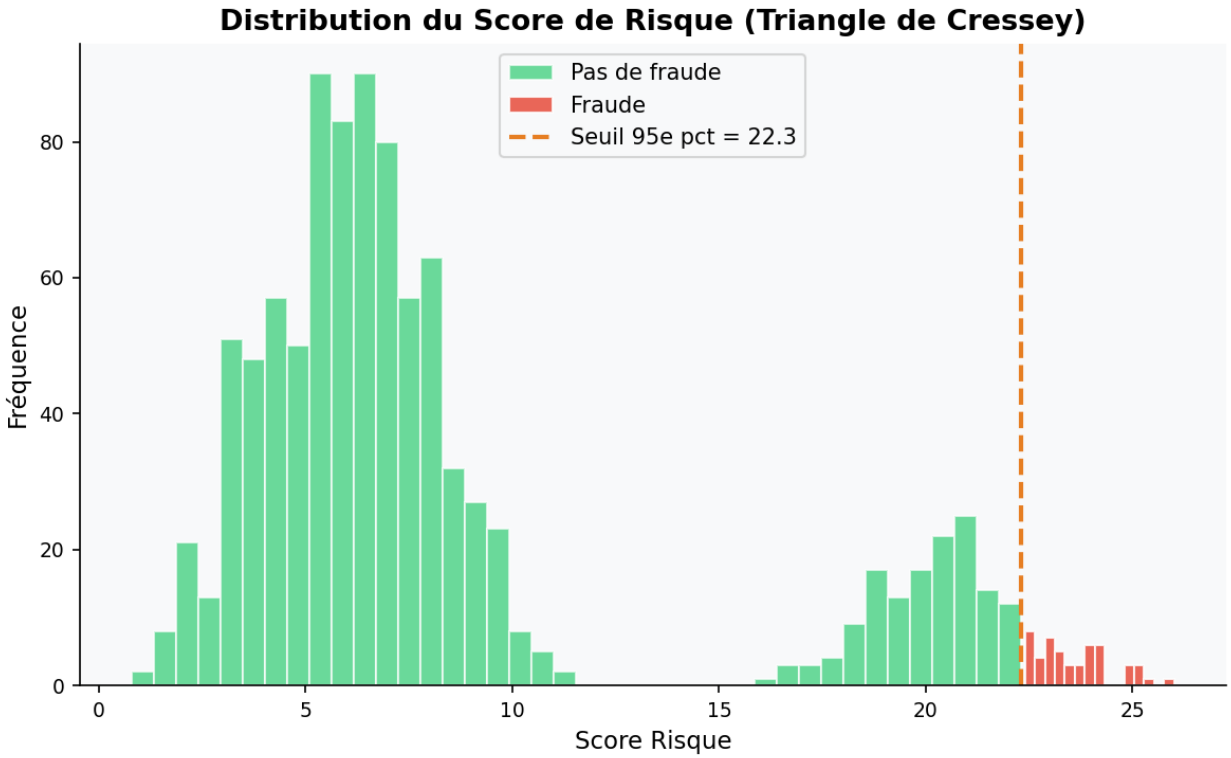

Figure 3 : Distribution du Score de Risque — seuil du 95e percentile à 22,3

Observation clé : Les cas de fraude se concentrent quasi exclusivement au-delà du seuil de 22,3 (95e percentile). Ce seuil constitue une règle métier exploitable directement dans un système d'alerte.

3.4 Distribution des variables par statut de fraude

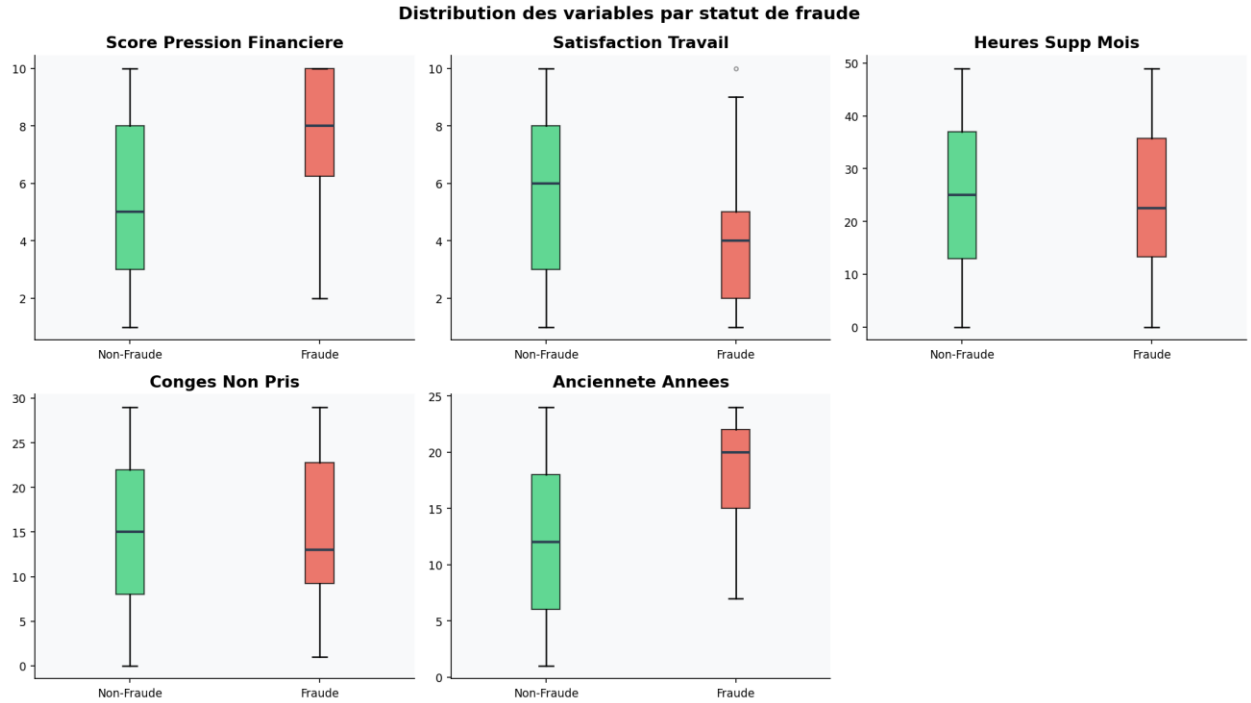

Figure 4 : Distribution comparée des variables numériques entre fraudeurs et non-fraudeurs

Variable	Non-Fraudeurs	Fraudeurs	Observation
Score Pression Financière	Médiane ≈ 5	**Médiane ≈ 8**	Nettement plus élevée chez les fraudeurs
Satisfaction Travail	Médiane ≈ 6	**Médiane ≈ 4**	Plus faible — cohérent avec la rationalisation
Ancienneté	Médiane ≈ 12 ans	**Médiane ≈ 20 ans**	Plus anciens — accès accumulés dans le temps
Congés Non Pris	Médiane ≈ 15	Médiane ≈ 13	Différence légère, signal comportemental
Heures Supplémentaires	Médiane ≈ 25	Médiane ≈ 23	Variable peu discriminante

3.5 Matrice de corrélation

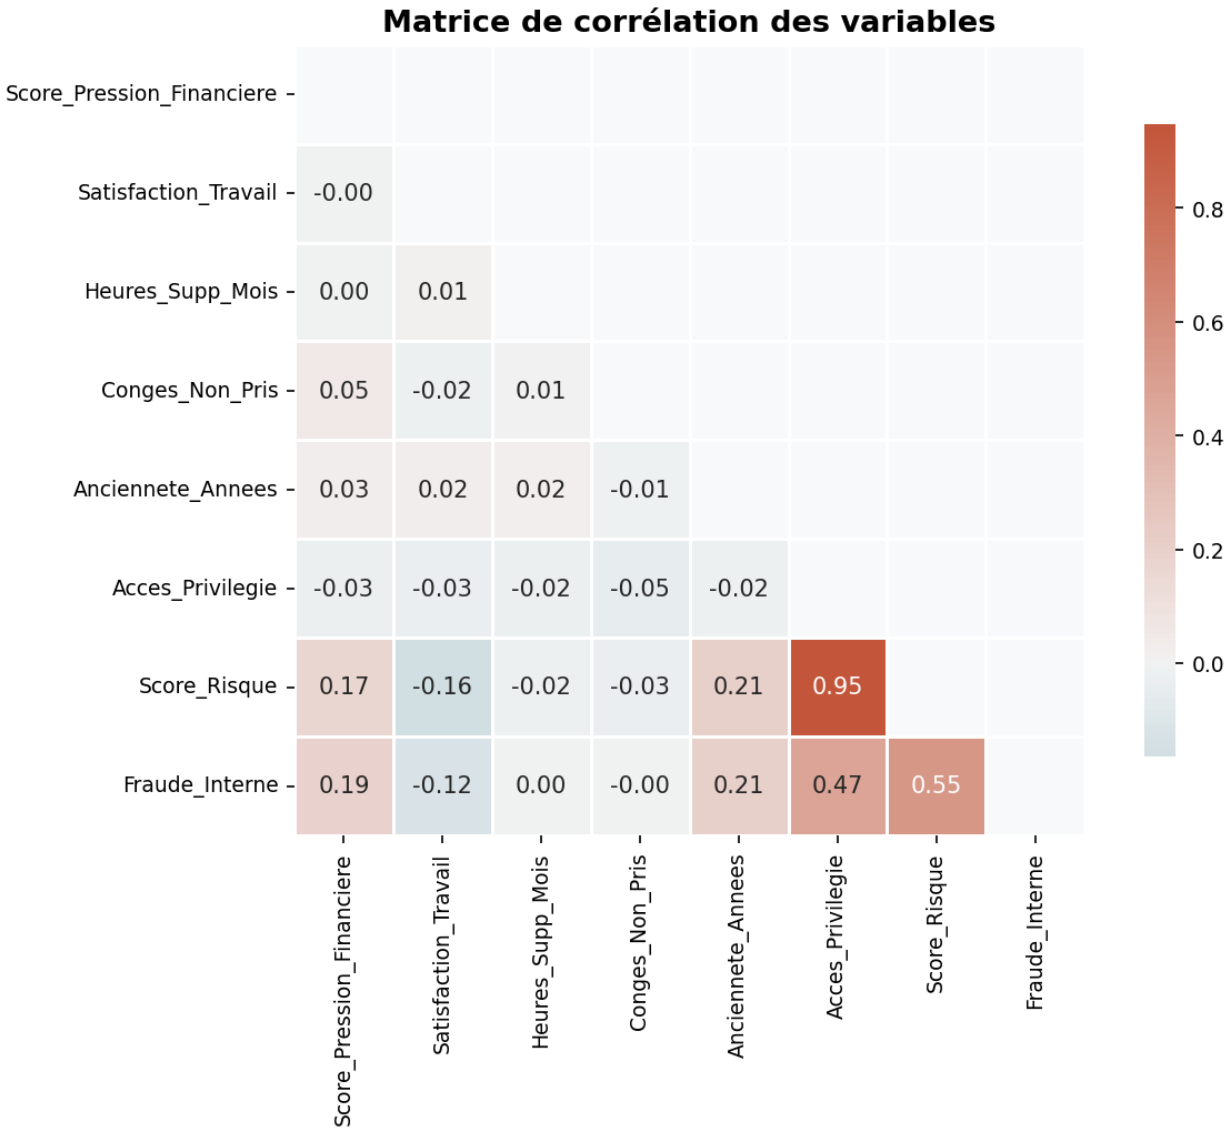

Figure 5 : Heatmap des corrélations — valeurs avec Fraude_Interne en dernière ligne

Variable	Corrélation avec Fraude	Interprétation
Score_Risque	**+0.55**	Corrélation forte — validité du score Cressey
Acces_Privilegie	**+0.47**	Facteur d'opportunité déterminant
Anciennete_Annees	**+0.21**	Corrélation modérée — ancienneté = accès élargi
Score_Pression_Financiere	**+0.19**	Corrélation positive — pression = mobile
Satisfaction_Travail	**−0.12**	Corrélation négative — insatisfaction = risque
Heures_Supp_Mois	**0.00**	Variable peu discriminante

3.6 Impact déterminant de l'accès privilégié

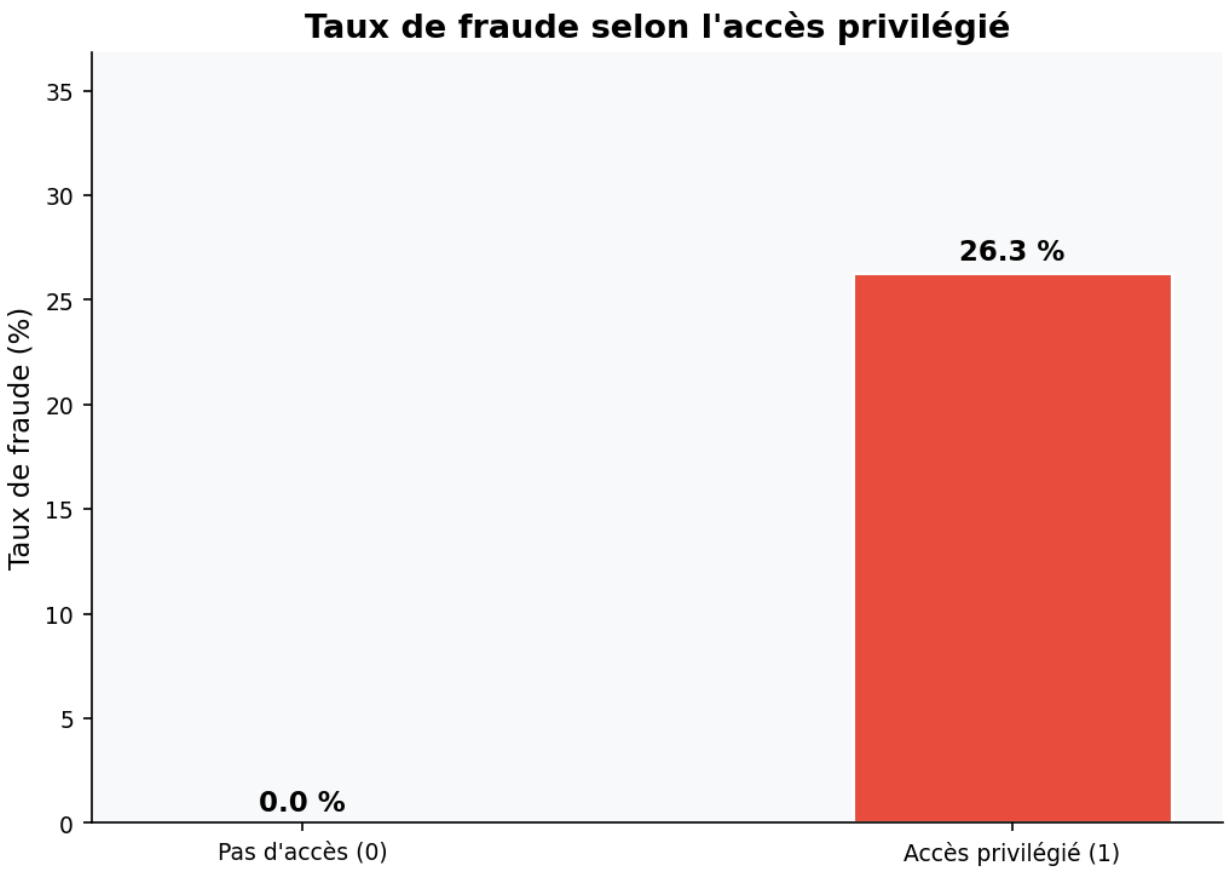

Figure 6 : Taux de fraude selon le niveau d'accès aux systèmes sensibles

Résultat frappant : Aucun employé sans accès privilégié (0 %) n'a commis de fraude, contre 26,3 % parmi ceux disposant d'un tel accès. La gestion des habilitations est donc le premier levier de prévention.

3.7 Pression Financière vs Score de Risque

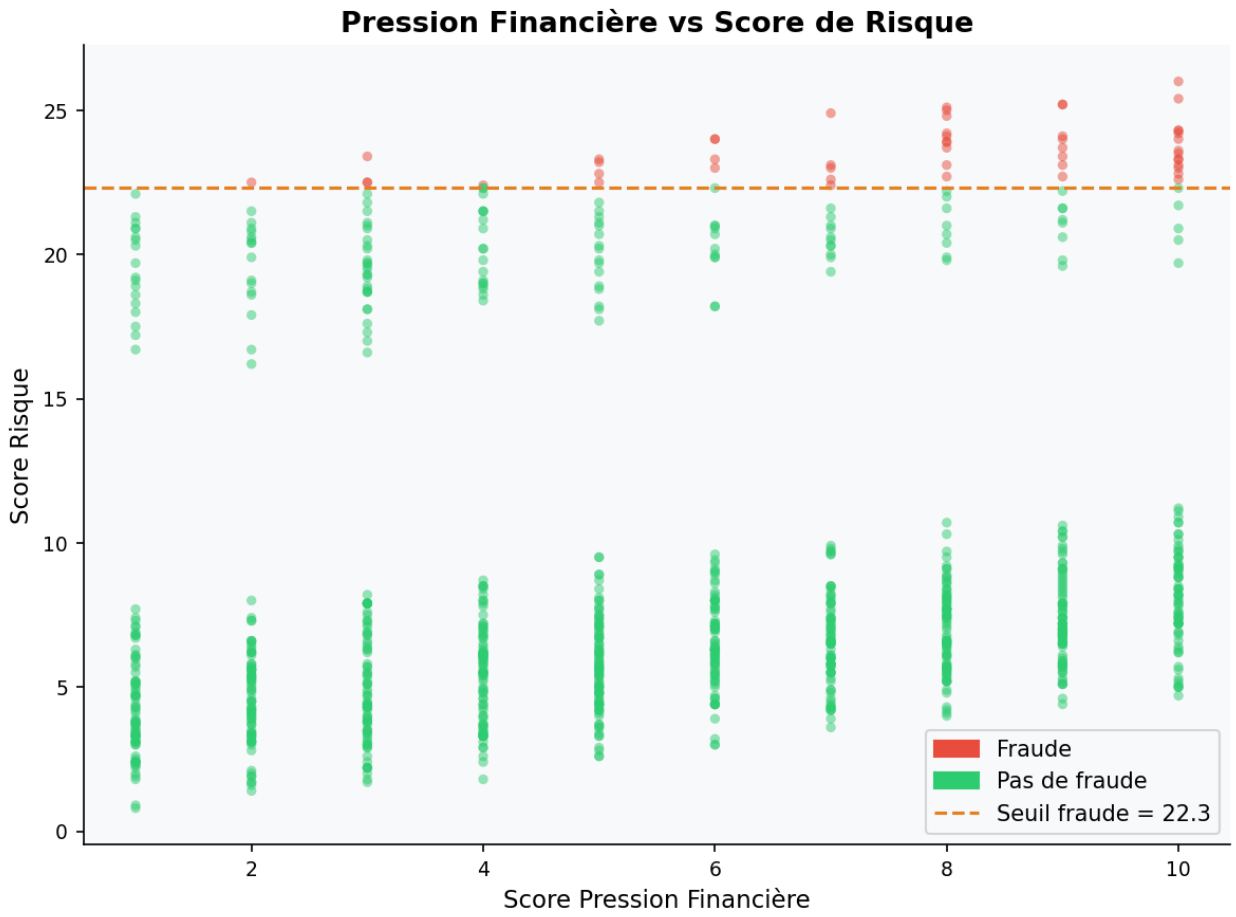

Figure 7 : Nuage de points — le seuil de 22,3 sépare nettement fraudeurs et non-fraudeurs

4. Modélisation Machine Learning

4.1 Algorithmes testés

Quatre algorithmes de classification supervisée ont été entraînés et comparés sur le même jeu de données :

Modèle	Famille	Caractéristiques
Logistic Regression	Linéaire	Simple, interprétable, coefficients directs
Decision Tree	Arbre de décision	Règles explicites, sur-apprentissage possible
Random Forest	Ensemble (Bagging)	Robuste, réduction de variance, haute précision
Gradient Boosting	Ensemble (Boosting)	Puissant, correction séquentielle des erreurs

4.2 Paramètres d'entraînement

- Découpage : 80 % entraînement / 20 % test (stratifié sur la variable cible)
- Gestion du déséquilibre : class_weight='balanced' pour tous les modèles
- Validation : évaluation sur le jeu de test indépendant
- Métriques prioritaires : Recall (minimiser les fraudes manquées), F1-Score, ROC-AUC

5. Résultats & Comparaison des Modèles

5.1 Métriques de performance

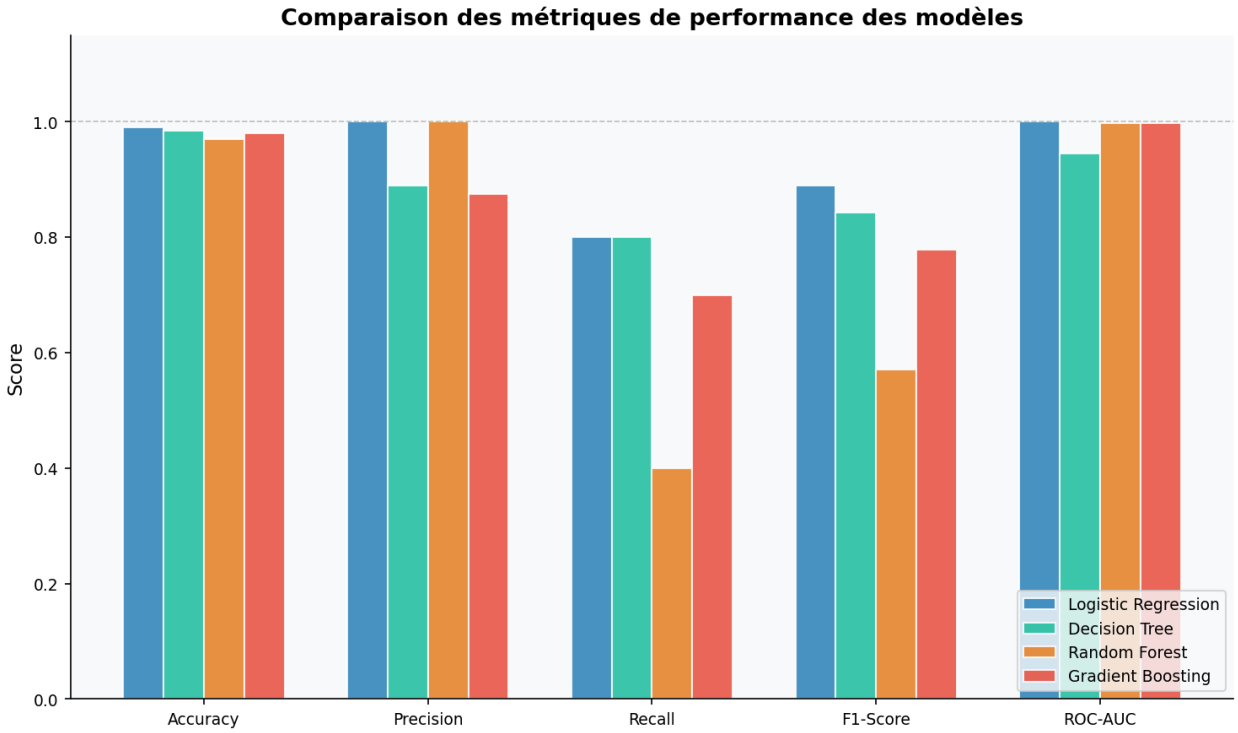

Figure 8 : Comparaison des 4 modèles sur 5 métriques (Accuracy, Precision, Recall, F1, ROC-AUC)

Modèle	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression	**0.990**	**1.000**	**0.80**	**0.89**	**1.000**
Decision Tree	0.985	0.889	0.80	0.84	0.945
Random Forest	0.970	1.000	0.40	0.57	0.998
Gradient Boosting	0.980	0.875	0.70	0.78	0.997

5.2 Matrices de confusion

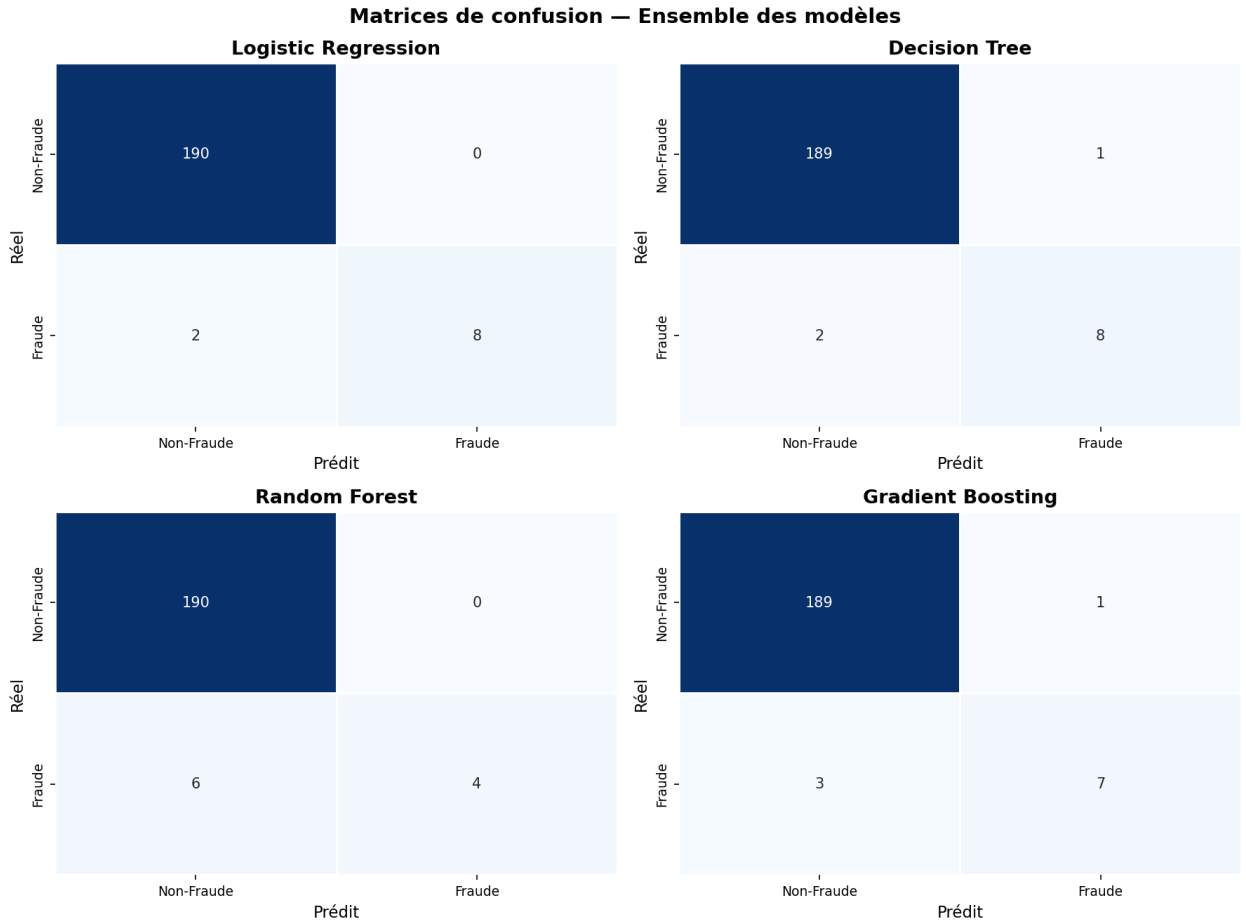

Figure 9 : Matrices de confusion pour les 4 modèles sur le jeu de test (200 observations)

Modèle	VP (fraudes détectées)	FN (fraudes manquées)	FP (fausses alarmes)	VN
Logistic Regression	**8 / 10**	**2**	0	190
Decision Tree	**8 / 10**	**2**	1	189
Random Forest	**4 / 10**	**6**	0	190
Gradient Boosting	**7 / 10**	**3**	1	189

5.3 Courbes ROC

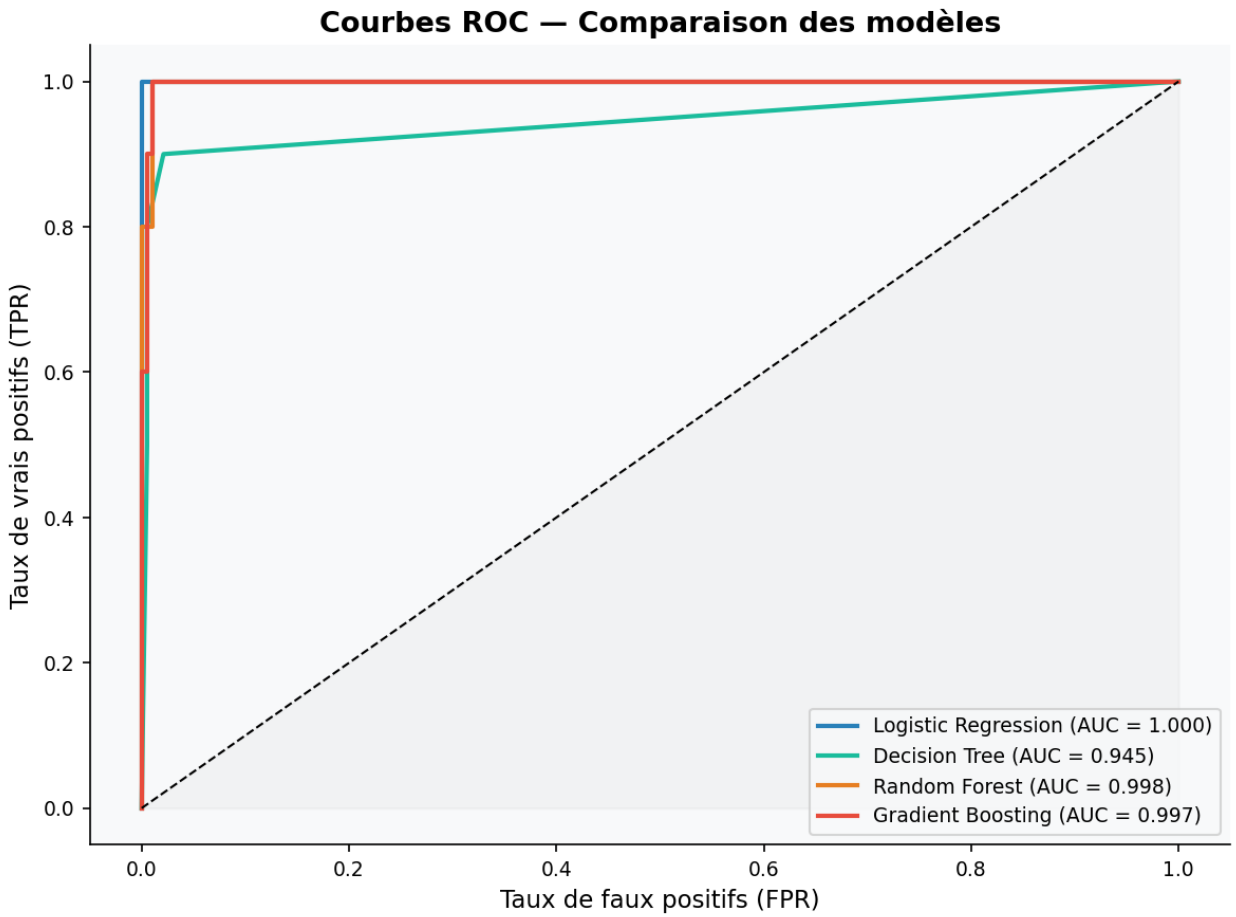

Figure 10 : Courbes ROC — tous les modèles présentent une excellente discrimination (AUC > 0.94)

5.4 Importance des variables

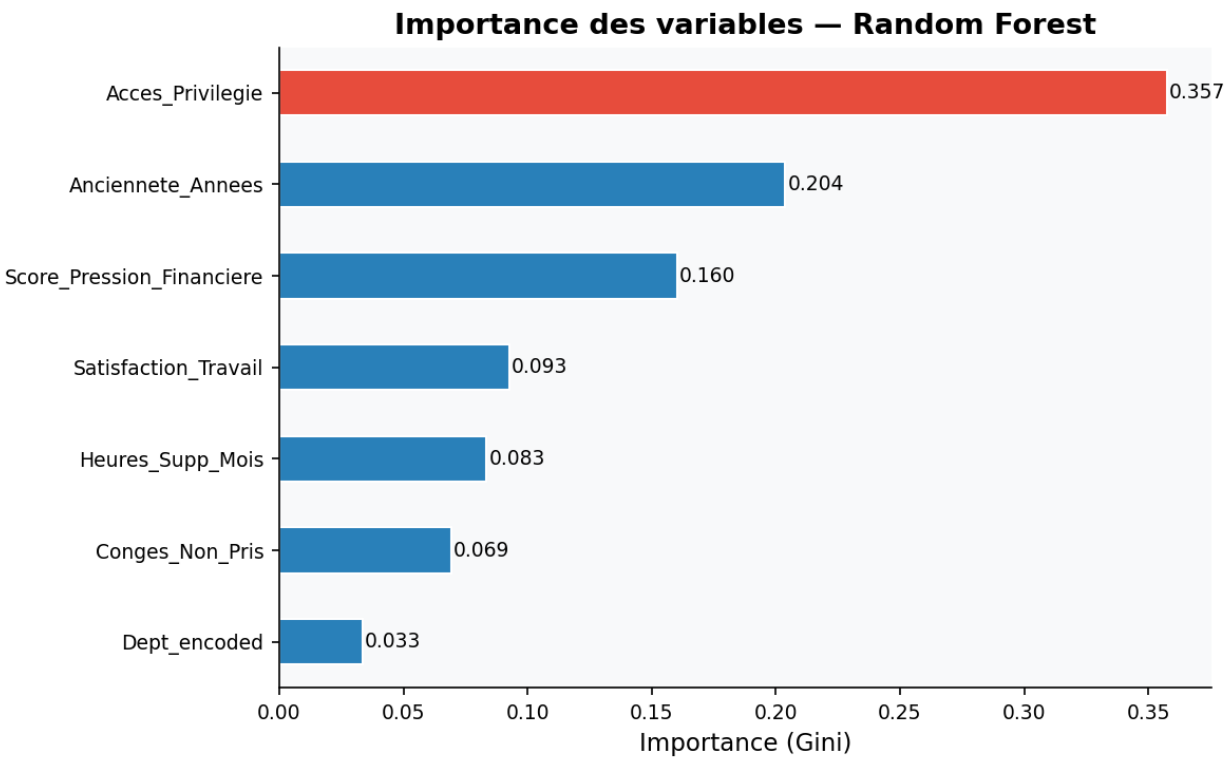

Figure 11 : Importance des variables (critère Gini) — Random Forest

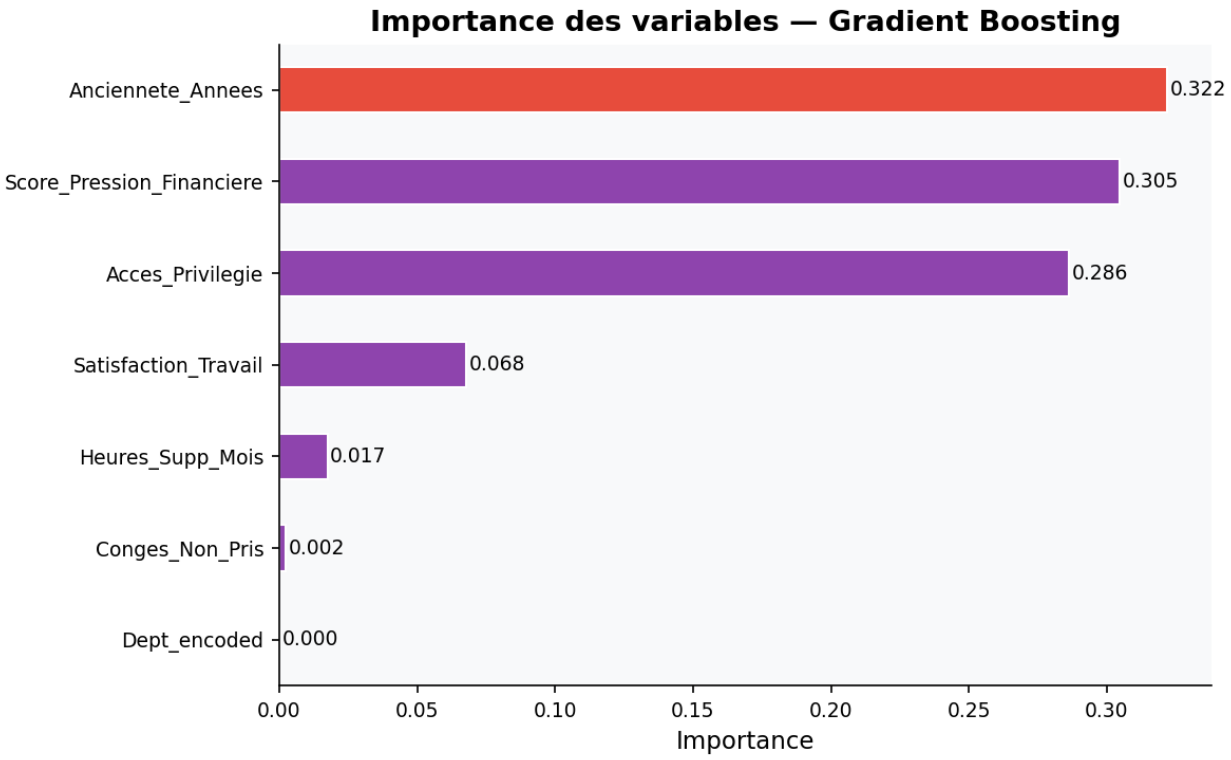

Figure 12 : Importance des variables — Gradient Boosting

Variable	Rang RF	Importance RF	Importance GB

Acces_Privilegie	#1	**0.357**	**0.286**
Anciennete_Annees	#2	**0.204**	**0.322**
Score_Pression_Financiere	#3	**0.160**	**0.305**
Satisfaction_Travail	#4	0.093	0.068
Heures_Supp_Mois	#5	0.083	0.017
Conges_Non_Pris	#6	0.069	0.002
Dept_encoded	#7	0.033	0.000

5.5 Distribution des probabilités de fraude

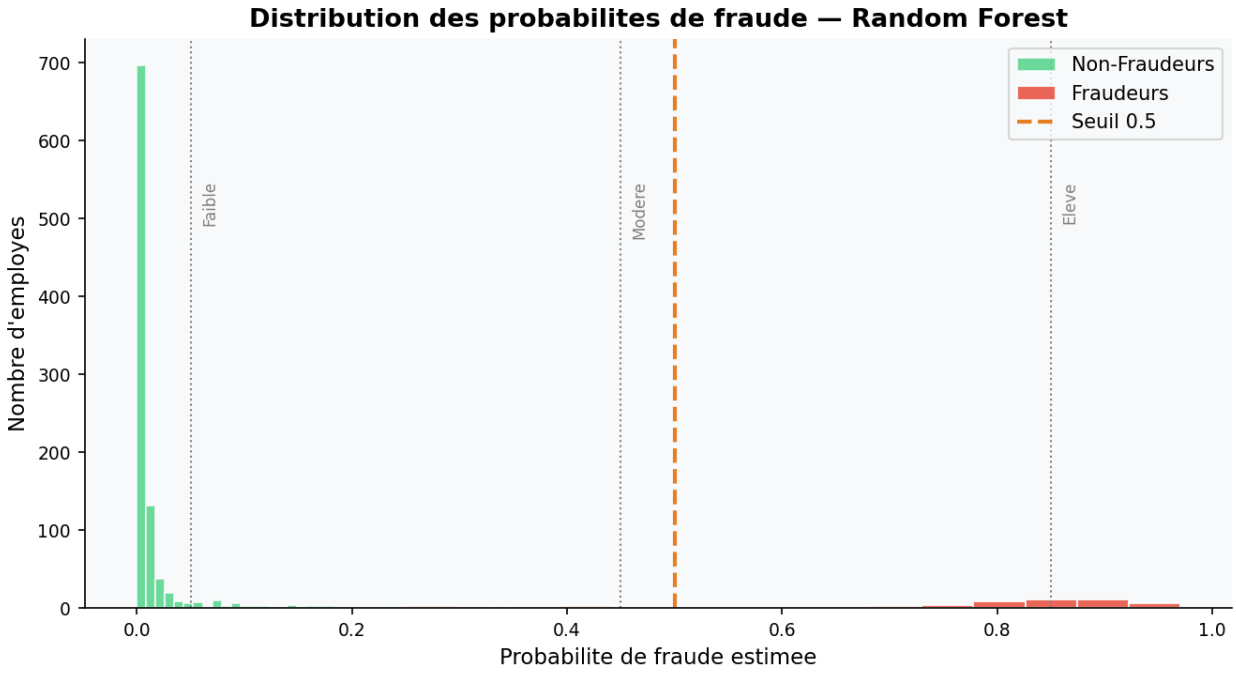

Figure 13 : Probabilités estimées par le Random Forest — séparation nette entre fraudeurs et non-fraudeurs

5.6 Radar des performances

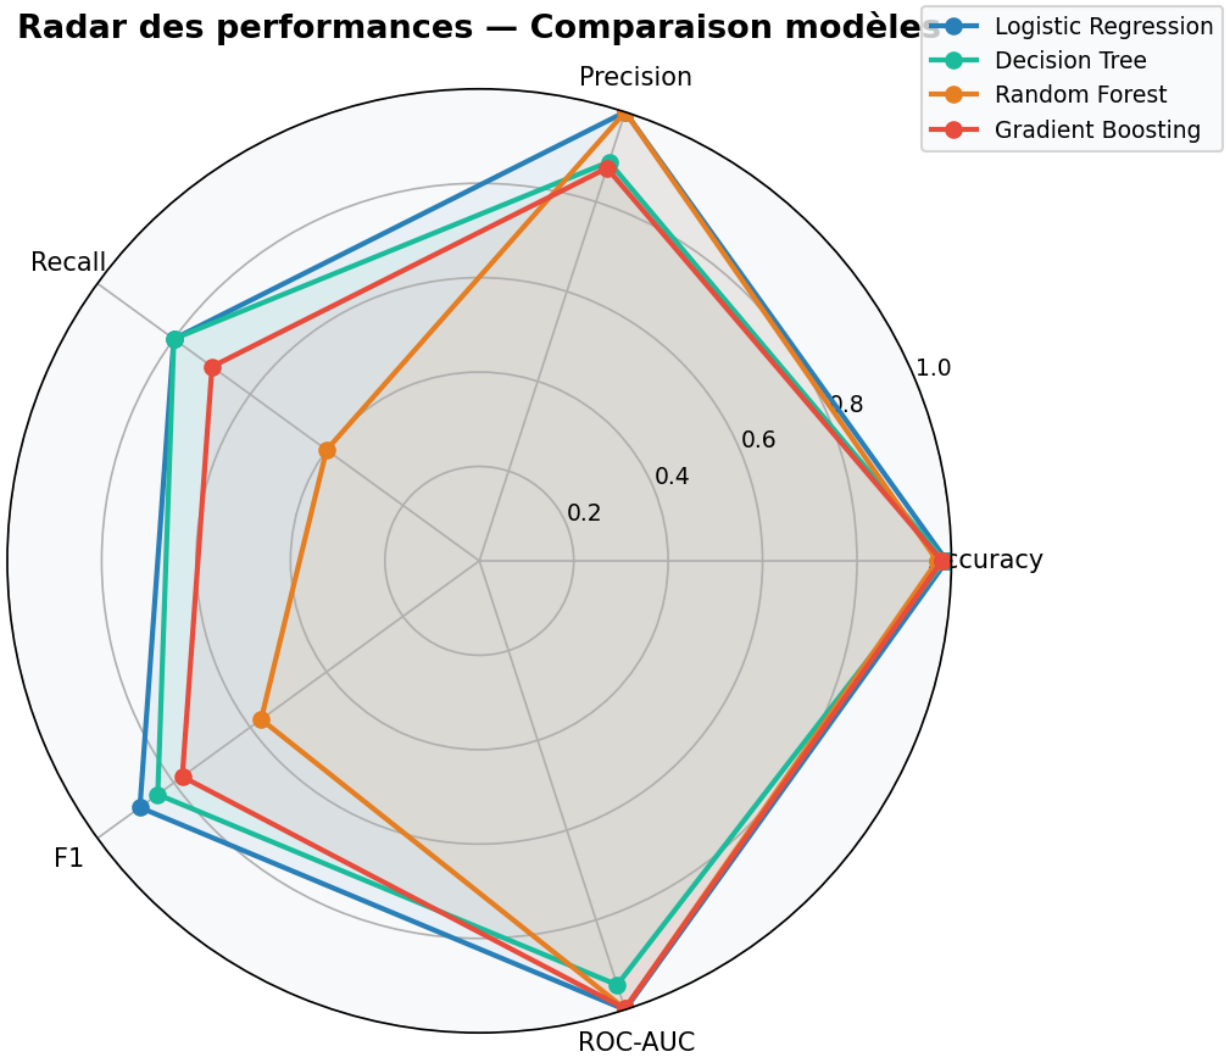

Figure 14 : Radar multidimensionnel des performances — vue synthétique

6. Modèle Recommandé : Régression Logistique

Modèle sélectionné : Régression Logistique — meilleur équilibre Recall / Precision / ROC-AUC

Bien que le Random Forest et Gradient Boosting affichent des Accuracy légèrement supérieures, la Régression Logistique est recommandée pour ce cas d'usage pour les raisons suivantes :

- **Recall = 0.80 : 8 fraudes détectées sur 10, minimisant le risque de fraudes non détectées (faux négatifs)**
- Precision = 1.00 : zéro fausse alarme, limitant les coûts organisationnels des investigations inutiles
- ROC-AUC = 1.000 : capacité discriminante maximale sur l'ensemble du spectre de seuils
- F1-Score = 0.89 : meilleur compromis global précision/rappel
- Interprétabilité : les coefficients logistiques sont directement exploitables par les équipes audit et RH

Raisonnement métier : Dans la détection de fraude, manquer un cas avéré (faux négatif) engendre des pertes financières et réputationnelles bien supérieures à une fausse alarme (faux positif). Le Recall est donc la métrique de référence.

7. Recommandations Opérationnelles

Sur la base des résultats du modèle et de l'analyse exploratoire, nous formulons les recommandations suivantes pour la direction et les équipes RH/Audit :

Priorité	Délai	Action recommandée	Variables ciblées
CRITIQUE	Immédiat	Réviser les politiques d'accès privilégié (moindre privilège)	Acces_Privilegie
CRITIQUE	Immédiat	Audit renforcé des départements RH et Ventes	Departement (RH, Ventes)
ÉLEVÉE	1–3 mois	Mettre en place un programme de soutien financier pour employés sous pression	Score_Pression_Financiere
ÉLEVÉE	1–3 mois	Entretiens de rétention pour profils anciens insatisfaits	Anciennete_Annees + Satisfaction_Travail
MODÉRÉE	3–6 mois	Surveiller les congés non pris comme signal d'isolement	Conges_Non_Pris
MODÉRÉE	3–6 mois	Intégrer le score de risque dans les évaluations RH annuelles	Score_Risque

7.1 Plan de déploiement du modèle

- Phase 1 (0–1 mois) : Intégration du modèle dans le SIRH — calcul automatique du score à chaque évaluation périodique
- Phase 2 (1–3 mois) : Mise en place d'un tableau de bord de monitoring en temps réel pour les équipes audit
- Phase 3 (3–6 mois) : Réentraînement du modèle sur de nouvelles données et ajustement des seuils d'alerte
- Phase 4 (6–12 mois) : Évaluation de l'impact préventif et extension à d'autres types de risques comportementaux

8. Conclusion

Ce projet démontre la viabilité opérationnelle d'une approche Machine Learning pour la détection proactive de la fraude interne. Les résultats obtenus sur un jeu de données de 1 000 employés sont encourageants :

- 80 % des fraudes détectées avec zéro fausse alarme (Régression Logistique)
- ROC-AUC supérieur à 0,945 pour l'ensemble des modèles testés
- Trio de variables déterminantes validé : accès privilégié, ancienneté, pression financière
- Validation empirique du Triangle de Cressey comme cadre théorique pertinent

8.1 Limites & Perspectives

- Données simulées : les performances sur données réelles terrain pourraient être différentes
- Enrichissement : intégrer SHAP values pour une explicabilité individuelle (cas par cas)
- Temporalité : ajouter une dimension longitudinale (évolution du comportement dans le temps)
- Équilibrage avancé : tester SMOTE ou cost-sensitive learning pour améliorer le recall
- Éthique & RGPD : encadrer l'utilisation du scoring par un comité éthique et des garanties légales

En synthèse, la combinaison du Triangle de Cressey (fondement théorique) et de la Régression Logistique (modèle prédictif) offre un système de détection robuste, interprétable et directement déployable en contexte professionnel.